Tugas Besar
Milestone 1

IF2224 Teori Bahasa Formal dan Otomata

Lexical Analysis

Semester 2 Tahun 2025/2026

Disusun oleh:

Kai

Jonathan Kris Wicaksono	(13524023)
Vincent Rionarlie	(13524031)
Muhammad Aufar Rizqi Kusuam	(13524061)
Bryan Pratama Putra Hendra	(13524067)

Laboratorium Ilmu dan Rekayasa Komputasi
Program Studi Teknik Informatika
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung

Daftar Isi

1 Pendahuluan **2**
1.1 Pengantar 2
1.2 Spesifikasi Program 3
1.2.1 Daftar Token Bahasa Pemrograman Arion 4
1.2.2 Contoh Input/Output 5

2 Dasar Teori **8**
2.0.1 Deterministic Finite Automata (DFA) 8
2.0.2 Token 10
2.0.3 Lexical Analysis 11

3 Perancangan dan Implementasi **13**

4 Pengujian **14**

5 Penutup **15**
5.1 Kesimpulan 15
5.2 Saran 15

6 Lampiran **16**
6.1 Tautan GitHub 16
6.2 Tautan Diagram Transisi DFA 16
6.3 Tabel Kontribusi 16

Bab 1

Pendahuluan

1.1 Pengantar

Apa itu **Bahasa Pemrograman?** Bahasa pemrograman adalah cara agar kita dapat menuliskan program komputer tanpa perlu menghadapi sulitnya menulis dalam bahasa mesin. Bahasa mesin (biner 1 dan 0) adalah satu-satunya bahasa yang dapat dipahami dan dijalankan oleh CPU, namun sangat sulit dibaca oleh manusia. Oleh karena itu, bahasa pemrograman sering kali dibedakan dengan istilah low-level atau high-level. High-level artinya bahasa lebih mendekati bahasa manusia dan sebaliknya low-level lebih mendekati bahasa mesin. Semakin mendekati bahasa manusia, maka akan semakin banyak proses yang diperlukan untuk mengubahnya menjadi kode mesin.

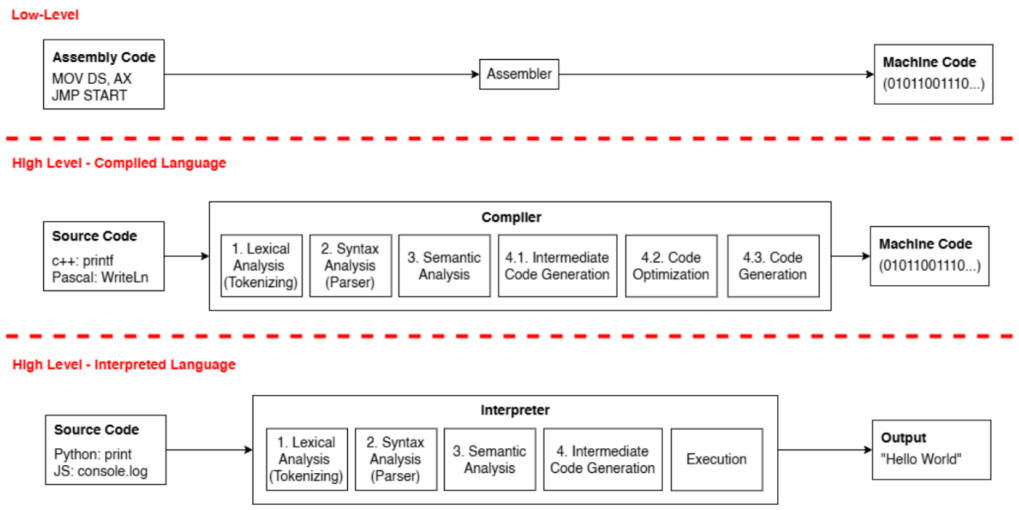

Gambar 1.1: Tipe-tipe bahasa pemrograman (Sumber: Asisten IF2224)

Terdapat dua macam cara mengubah/memproses bahasa pemrograman menjadi machine code, yaitu **compiler** dan **interpreter**. Compiler adalah program yang menerjemahkan seluruh source code menjadi kode mesin (dalam bentuk file e.g. Object File) sebelum program dijalankan. Compiler secara umum terdiri dari 4 tahapan, mulai dari Lexical Analysis, Syntax Analysis, Semantic Analysis hingga Intermediate Code Generation.

Di sisi lain adalah Interpreter yang memproses source code baris per baris secara langsung. Interpreter membaca, menerjemahkan, dan langsung mengeksekusi kode mesin baris per baris sehingga jika terdapat error pada baris ke 10, program akan tetap berjalan normal untuk 9 baris awal, dibandingkan dengan compiler yang akan gagal dijalankan jika terdeteksi terdapat error di dalam source code. Namun dibalik itu, interpreter sebenarnya memiliki tahapan yang sama seperti compiler.

Pada Tugas Besar Teori Bahasa Formal dan Automata, Mahasiswa diminta untuk membuat Compiler beserta Interpreter untuk bahasa pemrograman *Arion*, suatu bahasa pemrograman baru yang akan Anda kembangkan. Tugas besar ini dibagi menjadi 4 Milestone, yaitu Lexical Analysis, Syntax Analysis, Semantic Analysis, Intermediate Code Generation dan Interpreter. Setiap Milestone akan memiliki pengumpulannya dan penilaiannya tersendiri.

Pada **milestone pertama**, Mahasiswa diminta untuk membuat tahapan Lexical Analysis dari suatu compiler.

1.2 Spesifikasi Program

Pada milestone 1, Mahasiswa diminta untuk membuat **lexer** atau **lexical analyzer** dalam C/C++ yang menggunakan Deterministic Finite Automata (DFA) untuk menghasilkan token dari source code bahasa pemrograman Arion.

Dalam milestone ini, Mahasiswa diminta untuk membuat program Lexer dalam bahasa pemrograman C/C++ GNU. Mahasiswa **DILARANG** menggunakan library atau tools apapun yang dapat membantu menghasilkan lexical analyzer. Anda wajib menggunakan **MAKEFILE** untuk mempermudah pengembangan dalam bahasa C/C++.

Program Lexer harus berfungsi selayaknya suatu DFA. Program Lexer **HANYA BOLEH** membaca satu demi satu karakter dari input source code dan memprosesnya sesuai dengan aturan pada DFA. Program harus dapat menerima input source code dalam bentuk `.txt`. Program kemudian memproses source code dengan aturan DFA dan mengeluarkan output `daftar token` dalam format `.txt`.

1. Masukan : Kode Sumber (`.txt`)
2. Keluaran : Daftar Token (`.txt`)
3. Otomata : Deterministic Finite Automata

Catatan: Untuk mempermudah pengerjaan pada milestone-milestone selanjutnya, khususnya pada milestone 4 (pembuatan interpreter), SANGAT DISARANKAN agar program dikembangkan secara modular (terpisah antara komponen Lexer, Semantic, Syntax, dan Intermediate Code Generation). Hal ini supaya komponen dapat dimodifikasi sesuai keperluan tanpa mempengaruhi komponen lainnya, serta dapat dengan mudah dijalankan dalam satu pipeline: lexer - syntax - semantic - intermediate code generation.

1.2.1 Daftar Token Bahasa Pemrograman Arion

Lexer bertujuan untuk mengubah source code dari kumpulan karakter mentah menjadi unit-unit bermakna yang disebut token. Setiap token memiliki jenis (type) dan nilai (value) yang akan digunakan untuk tahap selanjutnya dalam proses kompilasi. Lexer diharapkan dapat menerima source code dan mengeluarkan daftar token yang dihasilkan. Berikut merupakan daftar token yang harus dapat dibaca oleh lexical analyzer.

Tabel 1.1: Daftar token bahasa Arion

No	Token	Definisi	Contoh Pemakaian
1	intcon	Konstanta integer	`1, 3, 48`
2	realcon	Konstanta bilangan riil	`3.14, 26.7`
3	charcon	Konstanta karakter singular, diapit dengan tanda petik tunggal	`'j', 'k', 't'`
4	string	Sekuens karakter, diapit dengan tanda petik tunggal	`'IRK', 'TBFO'`
5	notsy	Operator logika NOT (negasi)	`NOT`
6	plus	Operator aritmatika pertambahan	`+`
7	minus	Operator aritmatika pengurangan	`-`
8	times	Operator aritmatika perkalian	`*`
9	idiv	Operator aritmatika pembagian Integer	`div`
10	rdiv	Operator aritmatika pembagian Riil	`/`
11	imod	Operator aritmatika modulo	`MOD`
12	andsy	Operator logika AND	`AND`
13	orsy	Operator logika OR	`OR`
14	eql	equal	`==`
15	neq	Not equal	`<>`
16	gtr	Greater than	`>`
17	geq	Greater than or equal	`>=`
18	lss	Less than	`<`
19	leq	Less than or equal	`<=`
20	lparent	Left parentheses	`(`
21	rparent	Right parantheses	`)`
22	lbrack	Kurung siku kiri	`[`
23	rbrack	Kurung siku kanan	`]`
24	comma	Koma	`,`
25	semicolon	Titik koma	`;`
26	period	Titik	`.`
27	colon	Titik dua	`:`
28	becomes	Assignment operator	`:=`

No	Token	Definisi	Contoh Pemakaian
29	constsy	Deklarasi konstanta	`const`
30	typesy	Deklarasi tipe data	`type`
31	varsy	Deklarasi variabel	`var`
32	functionsy	Deklarasi fungsi	`function`
33	proceduresy	Deklarasi prosedur	`procedure`
34	arraysy	Deklarasi array	`array`
35	recordsy	Deklarasi record	`record`
36	programsy	Deklarasi program	`program`
37	ident	Nama yang menunjukkan konstanta, tipe, variabel, prosedur, dan fungsi; diawali huruf, diikuti huruf/angka; case-insensitive	`x, PI, MyInt, h4g`
38	beginsy	Keyword begin	`begin`
39	ifsy	Keyword if	`if`
40	casesy	Keyword case	`case`
41	repeatsy	Keyword repeat	`repeat`
42	whilesy	Keyword while	`while`
43	forsy	Keyword for	`for`
44	endsy	Keyword end	`end`
45	elsesy	Keyword else	`else`
46	untilsy	Keyword until	`until`
47	ofsy	Keyword of	`of`
48	dosy	Keyword do	`do`
49	tosy	Keyword to	`to`
50	downtosy	Keyword downto	`downto`
51	thensy	Keyword then	`then`
52	comment	Dimulai dengan { atau (* (bukan di dalam tanda kutip) dan diakhiri dengan } atau *)	`{ Ini komentar }`

1.2.2 Contoh Input/Output

Input

```
program Hello;

var
    a, b: integer;

begin
```

```
    a := 5;
    b := a + 10;
    writeln('Result = ', b);
end.
```

Visualisasi Pemrosesan (DFA)

```
p => State 1
r => State 1
.
m => State 2 => Gotten: program
.
H => State 3
e
.
; => char => State 0 => Gotten: ident(Hello) & semicolon
.
.
.
```

Output

```
programsy
ident (Hello)
semicolon

varsy
ident (a)
comma
ident (b)
colon
ident (integer)
semicolon

beginsy
ident (a)
becomes
intcon (5)
semicolon
ident (b)
becomes
ident (a)
plus
intcon (10)
semicolon
ident (writeln)
```

```
lparent
string ('Result = ')
comma
ident (b)
rparent
semicolon

endsy
period
```

Bab 2

Dasar Teori

2.0.1 Deterministic Finite Automata (DFA)

Secara intuitif, *Deterministic Finite Automata* (DFA) dapat dipahami sebagai "mesin pembaca" yang bergerak langkah demi langkah saat menerima karakter masukan. Pada setiap langkah, mesin selalu berada tepat pada satu keadaan (*state*) tertentu, lalu berpindah ke keadaan berikutnya berdasarkan karakter yang sedang dibaca. Sifat paling penting dari DFA adalah deterministik: untuk setiap pasangan keadaan dan simbol masukan, hanya ada satu perpindahan yang mungkin. Karena itu, perilaku DFA dapat diprediksi dan sangat cocok digunakan pada tahap lexical analysis yang menuntut keputusan cepat serta konsisten untuk setiap karakter yang dibaca dari kiri ke kanan [1, 2].

Secara formal, sebuah DFA didefinisikan sebagai *quintuple* di bawah ini

$$A = (Q, \Sigma, \delta, q_0, F).$$

Himpunan berhingga Q menyatakan semua state yang mungkin, Σ adalah himpunan simbol masukan, $\delta : Q \times \Sigma \to Q$ adalah fungsi transisi yang memetakan pasangan state beserta sebuah simbol masukan ke sebuah state lain, $q_0 \in Q$ adalah state awal dari mesin, dan $F \subseteq Q$ adalah himpunan *acceptance state*. Untuk sebuah string masukan w, DFA memproses simbol demi simbol melalui perluasan fungsi transisi $\hat{\delta}$, yaitu string dinyatakan diterima jika state akhir pemrosesan berada di dalam F. Formulasi ini memberi dasar matematis yang kuat untuk menyatakan apakah suatu pola leksikal termasuk bahasa yang diinginkan atau tidak [1, 2].

Lewat quintuple ini, dapat dimodelkan sebuah mesin yang dapat menerima sejumlah input karakter Σ, dengan state awal dari mesin adalah q_0, yang memiliki sejumlah state mesin disimpan dalam Q dan dapat berpindah-pindah dari satu state ke state yang lain menggunakan fungsi transisi δ. Sejumlah input karakter merupakan sebuah "bahasa" yang valid jika state akhir dari mesin tersebut berada pada himpunan state final F.

Komponen pembangun DFA pada implementasi lexer dapat dipetakan langsung dari definisi formal tersebut. State merepresentasikan konteks pembacaan token, misalnya state awal, state saat membaca identifier, state saat membaca bilangan, atau state saat berada di dalam komentar. Alfabet masukan berupa karakter-karakter source code yang relevan (huruf, digit, operator, delimiter, dan simbol khusus lain).

Fungsi transisi diwujudkan sebagai aturan *if/switch* yang menentukan state berikutnya untuk setiap karakter yang masuk. State awal dipakai ketika belum ada token yang sedang dibangun, sedangkan state penerima menandai bahwa pola token valid telah lengkap dan token siap di-*emit*. Dengan pemetaan ini, desain DFA tidak hanya teoretis, tetapi langsung menjadi kerangka arsitektur program lexer yang modular dan mudah diuji [3, 4].

Aplikasi DFA sangat luas pada perangkat lunak sistem, dan pada konteks tugas besar ini aplikasi utamanya adalah lexical analyzer/compiler front-end. DFA dipakai untuk mengenali lexeme seperti keyword, identifier, integer, real, operator, dan komentar secara efisien dalam waktu linear terhadap panjang input. Di luar compiler, konsep yang sama juga digunakan pada mesin pencocokan pola berbasis regular expression, penyaring teks, validasi format masukan, hingga sebagian mekanisme inspeksi paket pada jaringan yang membutuhkan klasifikasi string secara cepat dan deterministik. Karena kesederhanaan model serta jaminan performanya, DFA menjadi fondasi praktis yang menjembatani teori bahasa formal dengan implementasi perangkat lunak nyata [3, 1].

Sebagai ilustrasi konkret, perhatikan DFA sederhana yang dirancang untuk menerima semua string yang dimulai dengan "01" (atas alfabet biner $\{0, 1\}$). DFA ini memiliki empat state: state awal q_0, state setelah membaca '0' yaitu q_1, state penerima q_2 yang dicapai setelah membaca "01", dan *dead state* q_3 yang merepresentasikan penolakan (karena pola tidak cocok).

Diagram transisi DFA tersebut dapat divisualisasikan sebagai berikut.

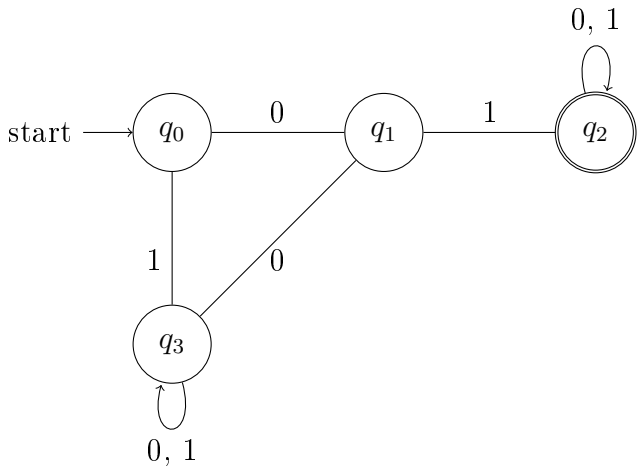

Gambar 2.1: Diagram transisi DFA untuk menerima string dimulai dengan "01" (dengan dead state)

Diagram transisi di atas juga dapat direpresentasikan dengan menggunakan sebuah tabel transisi. Semua kombinasi state dan simbol masukan memiliki transisi yang jelas (sesuai dengan konsep DFA itu sendiri). Berikut adalah tabelnya.

State	0	1
$\rightarrow q_0$	q_1	q_3
q_1	q_3	q_2
$q_2\star$	q_2	q_2
q_3	q_3	q_3

Tabel 2.1: Tabel transisi DFA untuk string dimulai dengan "01"

Dead state (atau *reject state*) adalah state yang bukan penerima dan dari mana mesin tidak dapat keluar menuju state penerima. Setelah mesin memasuki dead state, ia akan tetap berada di state tersebut untuk semua input yang tersisa, sehingga string otomatis ditolak. Dalam kasus ini, q_3 merupakan sebuah dead state. Sekali mesin tersebut masuk ke dalam state q_3, maka apapun masukan selanjutnya akan tetap membuat mesin berada pada q_3. Penggunaan dead state penting untuk menjamin bahwa fungsi transisi δ selalu terdefinisi untuk setiap kombinasi state dan simbol masukan, sesuai dengan definisi formal DFA.

Proses penerimaan string dapat diikuti langkah demi langkah. Sebagai contoh, Untuk string masukan "`0110`": dimulai dari q_0, karakter '0' membawa ke q_1; karakter '1' membawa ke q_2 (state penerima); karakter '1' tetap di q_2; karakter '0' tetap di q_2. Pada akhir string, mesin berada di state penerima q_2, sehingga "`0110`" diterima.

Contoh yang lain, Untuk string "`10`" yang dimulai dengan '1', mesin membaca '1' dari q_0 dan berpindah ke dead state q_3; kemudian membaca '0' dari q_3 dan tetap di q_3. Pada akhir string, mesin berada di dead state q_3, sehingga string ditolak.

2.0.2 Token

Token adalah unit terkecil dari source code yang bermakna dan dapat dikenali oleh lexer. Dalam konteks analisis leksikal, *token* berfungsi sebagai jembatan antara rangkaian karakter mentah (source code) dan struktur sintaksis yang akan diproses oleh parser pada tahap berikutnya. Setiap token terdiri dari dua komponen utama: tipe token (*token type*) dan nilai token (*token value*). Tipe token mengidentifikasi kategori semantik dari token tersebut—misalnya apakah token itu keyword, identifier, operator, atau literal konstanta. Nilai token merupakan string spesifik yang dikembalikan dari source code, digunakan khususnya untuk token yang memerlukan informasi detail seperti identifier berupa "x" atau konstanta berupa "42".

Contoh sederhana dari rangkaian token adalah sebagai berikut. Jika source code berisi pernyataan "`x := 10`", lexer akan menghasilkan tiga token: (1) token dengan tipe IDENT dan nilai " x", (2) token dengan tipe BECOMES dan tanpa nilai khusus, dan (3) token dengan tipe INTCON dan nilai "10". Setiap token menyimpan informasi tambahan seperti nomor baris dan kolom tempat token ditemukan, membantu dalam pelaporan error yang akurat jika diperlukan pada tahap parsing atau analisis semantik.

Klasifikasi token dalam bahasa pemrograman umumnya mencakup beberapa kategori besar. Kategori pertama adalah *keyword* atau kata kunci, yang merupakan simbol-simbol tereservasi dengan makna khusus dalam bahasa, seperti "`if`", "`while`", atau "`function`". Kategori kedua adalah *identifier*, yang merupakan nama-nama yang didefinisikan oleh programmer untuk variabel, fungsi, atau tipe data, dan

umumnya bersifat case-insensitive di bahasa tertentu. Kategori ketiga adalah *konstanta atau literal*, yang merepresentasikan nilai tetap seperti bilangan integer ("`42`"), bilangan riil ("`3.14`"), karakter ("`'a'`"), atau string ("`'hello world'`"). Kategori keempat adalah *operator*, yang merupakan simbol untuk operasi aritmatika ("`+`", "`-`"), logika ("`and`", "`or`"), atau perbandingan ("`==`", "`<`"). Kategori kelima adalah *delimiter atau punctuation*, yaitu simbol-simbol struktural seperti tanda kurung, koma, titik koma, dan titik. Terakhir, kategori keenam mencakup *komentar*, yang merupakan teks yang tidak mempengaruhi semantik program dan umumnya dibuang atau disimpan terpisah oleh lexer.

Peran token sangat penting dalam pipeline kompilasi modern. Dengan mengubah rangkaian karakter menjadi token, lexer menyederhanakan tugas parser: daripada parser harus menangani jutaan karakter individual, parser bekerja dengan puluhan atau ratusan token yang sudah terklasifikasi. Hal ini meningkatkan efisiensi dan kejelasan dari analisis sintaksis. Lebih lanjut, dengan mendeteksi error leksikal—seperti simbol yang tidak dikenal—pada tahap lexical analysis, proses kompilasi secara keseluruhan menjadi lebih robust dan memudahkan programmer untuk mengidentifikasi dan memperbaiki kesalahan [3, 1].

2.0.3 Lexical Analysis

Analisis leksikal (*lexical analysis*) adalah tahap pertama dalam proses kompilasi atau interpretasi suatu bahasa pemrograman. Pada tahap ini, compiler membaca kode sumber yang pada awalnya hanya berupa rangkaian karakter mentah dan mengubahnya menjadi rangkaian token bermakna. Proses ini sangat krusial karena menjadi pondasi bagi semua tahap analisis berikutnya. Tanpa hasil tokenisasi yang akurat, tahap parsing (syntax analysis) pada langkah berikutnya tidak dapat berjalan dengan baik. Lexical analysis memisahkan tugas pengenalan pola leksikal dasar (karakter demi karakter) dari tugas analisis struktur gramatikal yang lebih kompleks, sehingga meningkatkan modularitas dan maintainability dari compiler secara keseluruhan.

Komponen utama yang bertanggung jawab atas lexical analysis disebut *lexer* atau *scanner*. Lexer adalah program atau modul yang membaca input source code secara sekuensial dari kiri ke kanan, karakter per karakter, dan mengidentifikasi pola-pola yang sesuai dengan definisi token bahasa yang ditargetkan. Implementasi lexer modern umumnya berbasis DFA atau NFA (Nondeterministic Finite Automata), yang memungkinkan pengenalan pola dengan efisiensi tinggi. Pada setiap tahap pembacaan, lexer menentukan apakah karakter yang sedang dibaca merupakan lanjutan dari token sebelumnya ataukah awal dari token baru. Ketika lexer menemukan bahwa pola karakter telah lengkap dan sesuai dengan definisi token, lexer akan memancarkan (emit) token tersebut ke dalam output token stream.

Proses lexical analysis secara umum mengikuti alur berikut: pertama, lexer membaca karakter masukan satu per satu menggunakan buffer atau pointer masukan. Kedua, berdasarkan karakter yang dibaca dan state DFA saat ini, lexer melakukan transisi ke state berikutnya atau menyelesaikan pembacaan satu token. Ketiga, ketika lexer mendeteksi batas token (misalnya ketika karakter berikutnya bukan bagian dari token saat ini), lexer melakukan klasifikasi terhadap lexeme yang

terkumpul dan memancarkan token yang sesuai. Keempat, lexer kembali ke state awal dan siap membaca lexeme berikutnya. Selama proses ini, lexer juga menangani karakter-karakter non-esensial seperti whitespace (spasi, tab, newline), komentar, dan simbol-simbol lain yang tidak berkontribusi pada semantik program.

Pembuangan whitespace dan komentar selama lexical analysis memiliki tujuan penting. Whitespace seperti spasi dan indentasi membantu programmer membaca kode dengan lebih mudah, tetapi tidak mempengaruhi semantik program (kecuali pada bahasa tertentu seperti Python). Komentar adalah teks yang disisipkan programmer untuk dokumentasi dan juga tidak mempengaruhi eksekusi program. Dengan membuang elemen-elemen ini di tahap lexical analysis, lexer mengurangi beban kerja parser dan meningkatkan efisiensi keseluruhan. Namun, informasi baris dan kolom tempat setiap token ditemukan tetap disimpan dalam representasi token, sehingga jika terjadi error di tahap berikutnya, compiler dapat melaporkan lokasi error dengan akurat kepada programmer.

Output dari lexical analysis adalah token stream, yaitu urutan token-token yang telah terklasifikasi dan siap untuk diproses oleh parser. Token stream ini biasanya disimpan dalam struktur data seperti array atau linked list, atau dalam beberapa implementasi, di-stream secara on-demand ke parser. Setiap token dalam stream menyimpan informasi lengkap: tipe token, nilai token (jika ada), dan metadata lokasi (baris dan kolom). Format output yang terstandarisasi dan terstruktur ini memastikan bahwa parser dapat fokus pada analisis struktur gramatikal tanpa perlu terganggu oleh detail-detail karakter level yang kompleks [3, 4].

Bab 3

Perancangan dan Implementasi

Bab 4

Pengujian

Bab 5

Penutup

5.1 Kesimpulan

5.2 Saran

Bab 6

Lampiran

6.1 Tautan GitHub

Link GitHub

6.2 Tautan Diagram Transisi DFA

6.3 Tabel Kontribusi

No	Nama Lengkap	NIM	Deskripsi Pekerjaan	Persentase Kontribusi (%)
1	Jonathan Kris Wicaksono	13524023	Memrogram konsep	25
2	Vincent Rionarlie	13524031	Melakukan pembagian tugas, mendesain diagram transisi DFA	25
3	Muhammad Aufar Rizqi Kusuam	13524061	Menyusun laporan akhir	25
4	Bryan Pratama Putra Hendra	13524067		25

Bibliografi

[1] J. E. Hopcroft, R. Motwani, and J. D. Ullman, *Introduction to Automata Theory, Languages, and Computation*, 3rd ed. Pearson, 2006.

[2] M. Sipser, *Introduction to the Theory of Computation*, 3rd ed. Cengage Learning, 2012.

[3] A. V. Aho, M. S. Lam, R. Sethi, and J. D. Ullman, *Compilers: Principles, Techniques, and Tools*, 2nd ed. Addison-Wesley, 2007.

[4] D. Grune, K. van Reeuwijk, H. E. Bal, C. J. H. Jacobs, and K. Langendoen, *Modern Compiler Design*, 2nd ed. Springer, 2012.